NC-2610 — Evidência: Redução de ~53% no P95 do Endpoint Compact Offer

Lukasz Izai Torres Fokin | Graph snapshots | Unrestricted access

NC-2610 — Evidência: Redução de ~53% no P95 do Endpoint Compact Offer

Deploy: **2026-03-02** → Unificação de 3 chamadas HTTP ao `database-core` em 1 único endpoint (`GET /api/v1/econsignado/offer-decision-data/{person_id}`)

Métrica	Antes (release-20260226)	Depois (release-20260302)	Redução
P95 (BFF)	~1,5s	~0,74s	**-53%** ✅
AVG (BFF)	1,71s	0,79s	**-54%** ✅
Chamadas ao database-core	3 por request	1 por request	**-67%** ✅
Volume do endpoint	~300k req/dia	~300k req/dia	—

> Baseline: `release-20260226-180515-47caa0e` · Pós-deploy: `release-20260302-135216-3bdc7ec`

Contexto: O endpoint `compact offer` (`GET /econsignado/offer-decision-data`) é um dos mais acessados da jornada do Novo Consignado (~300k req/dia). Ele direciona o cliente para um dos fluxos: Finalização, Revisão, Refinanciamento, Troca de Dívida ou New Loan. Antes da otimização, realizava 3 chamadas HTTP separadas ao `database-core` para tomada de decisão; após, 1 única chamada unificada.

PRs: database-core#842 · database-service#125 · loan-core#2120 · loan-core#2125

1. P95 por Versão — BFF (`loans.e-consignado-bffmobile`)

Comparação direta entre a versão anterior (`release-20260226`) e a nova versão (`release-20260302`) no serviço BFF. A queda é visível logo após o deploy em 2026-03-02.

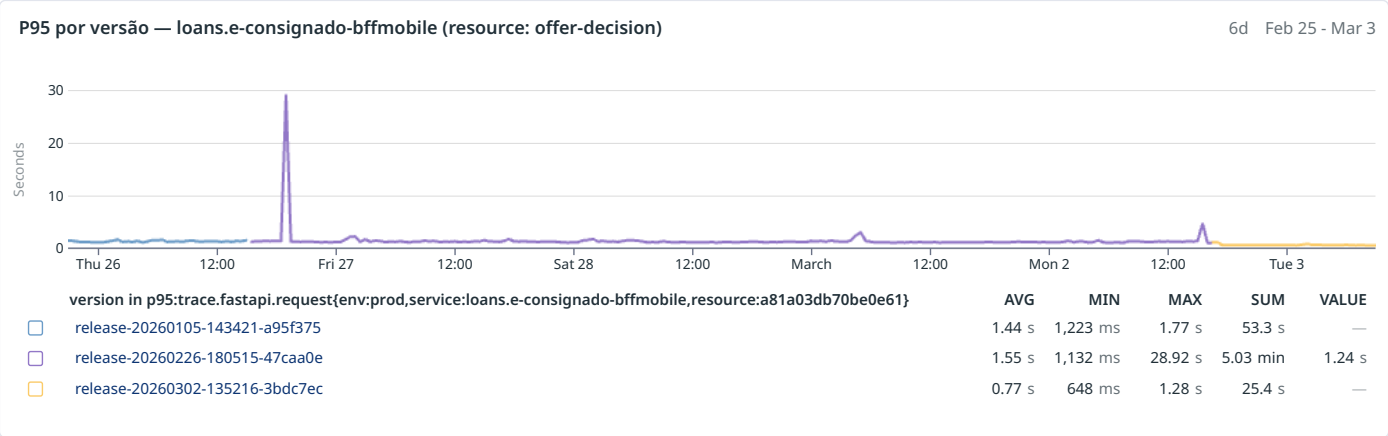

2. Latência Multi-Percentil — API Gateway (`api.somosleve.com.br`)

Visão do endpoint público (`GET /econsignado/...`). A queda em todos os percentis confirma o impacto real para o cliente após o deploy.

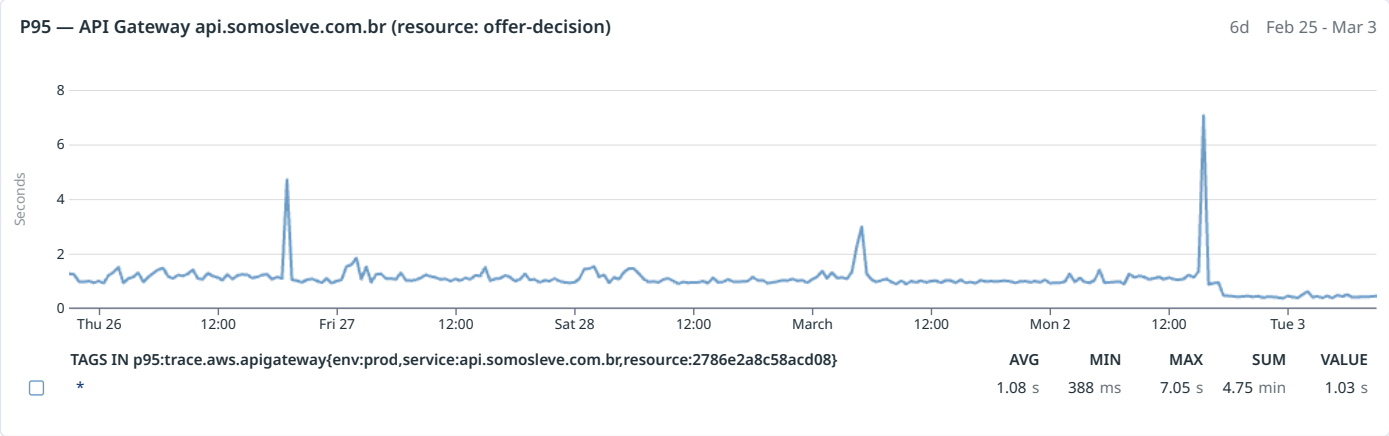

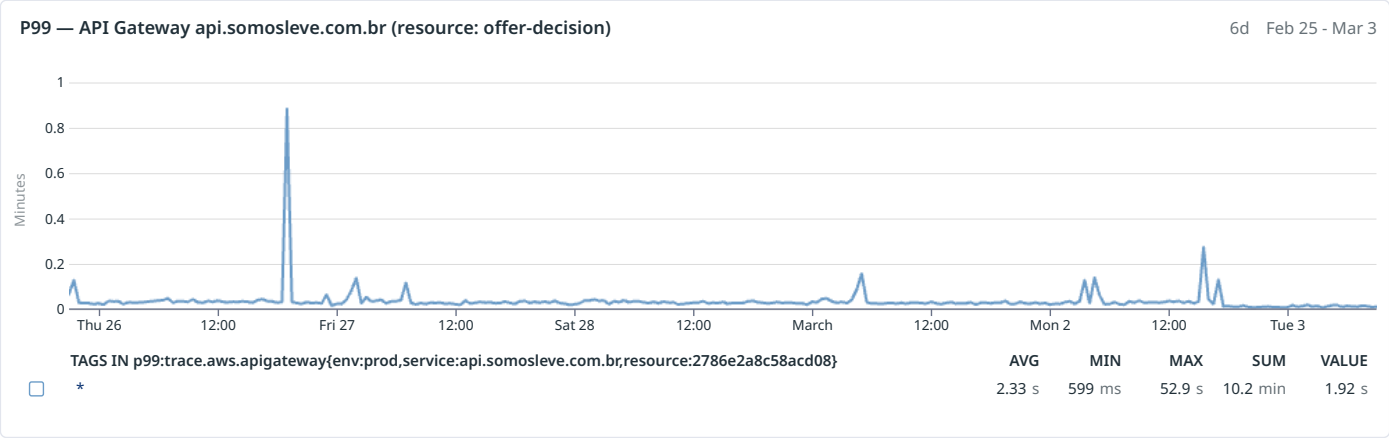

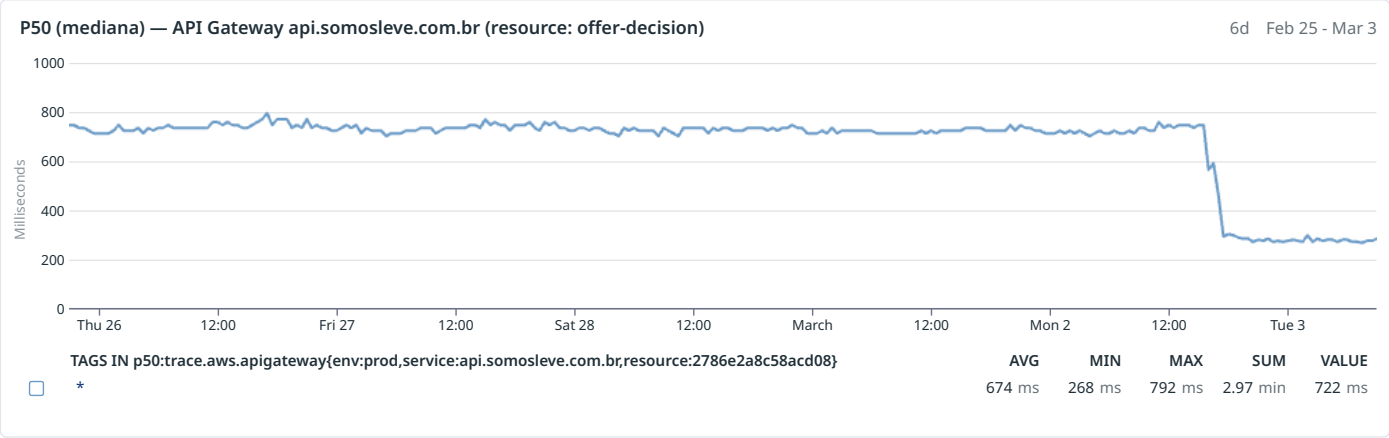

3. Volume de Requisições — Validação de Estabilidade

Confirmação de que o volume de requisições permaneceu estável antes e após o deploy, validando que a redução de latência não é artefato de queda de tráfego.

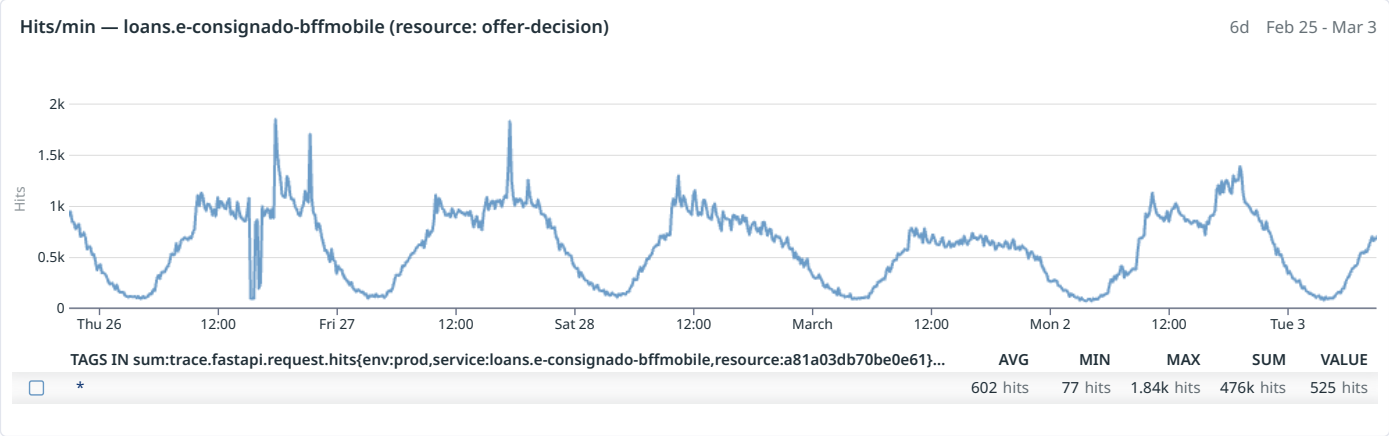

Conclusão

Card	NC-2610
Deploy	2026-03-02
Redução P95	~1,5s → ~0,74s (**-53%**)
Abordagem	Unificação de 3 chamadas HTTP → 1 (`offer-decision-data`) com feature flag para rollout seguro
Impacto	~300k req/dia com latência reduzida; KPI de engenharia de latência atingido
Repositórios	`loans.database-core`, `loan.database-service`, `loans.loan-core`

> Notebook criado como evidência de entrega para avaliação de engenharia (H1 2026).